


一种基于深度学习的交通流预测方法

董金雨 崔 璨



董金雨 崔 璨
沈阳航空航天大学民用航空学院

智能交通系统 (Intelligent Transportation System, 简称 ITS) 是指将先进的计算机, 电子信息, 传感器等技术运用于交通运输控制与决策中, 以构建更加安全高效的交通运输环境。在 ITS 的构建中, 运用大数据进行短时交通流预测起着重要作用。实现短时交通流的预测, 可以帮助交管部门对复杂的交通状况进行监测和预测, 以便及时采取措施展开交通管理和疏导; 也可帮助出行者了解实时交通运行状态并作出合理安排, 对交通拥堵的改善具有积极影响。因此, 本文将道路短时交通流的预测作为研究对象, 建立多因素复杂交通环境下的车流量预测模型。

对于短时交通流的预测方法十分丰富, 传统交通流预测方法如统计理论模型有非参数回归, 卡尔曼滤波等; 交通仿真模型有多目标动态规划, 元胞自动机等; 智能算法模型有神经网络, 支持向量回归等。目前, 深度学习等人工智能算法的应用较好地解决了传统交通流预测过程中的数据缺失、预测精度不高、模型的泛化能力不强等问题, 在城市道路交通流量预测、车辆行程时间预测、路网交叉口交通流量预测等领域取得较好的效果, 在数据的使用以及预测精度上都有更好的表现。

交通流数据是一种拥有较强时间序列规律变化的数据集。在对道路的短时交通流预测过程中, 道路突发事件, 天气温度等变化都会对交通流量造成显著影响。长短期记忆网络 (LSTM) 作为循环神经网络 (RNN) 的优化已经广泛应用于时间序列预测问题, 陈治亚等采用 LSTM 网络对交通流实现多维度因素下的预测, 并验证考虑多种因素的影响下预测精度更高。晏臻等采用了 CNN-LSTM 组合模型, 从序列特征捕捉的层面优化 LSTM 提升预测精度, 但 CNN-LSTM 组合模型在面临长序列, 多维度数据时仍会出现多维特征提取不充分的问题。据此本文采用 CNN-BiLSTM 挖掘数据的时间特征以及深层空间特征, 同时采用 CBAM 注意力机制优化 CNN, 从通道和空间两个层面进行权重分配, 提升特征提取能力。

模型的建立

双向长短期记忆网络 BiLSTM

循环神经网络 (RNN) 模型用于时间序列数据时拥有时序特征的提取能力, 但面临较长序列产生的梯度消失问题不可避免, LSTM 通过引入门控单元为主信息流增减信息实现了长期依赖处理能力, 并通过求和操作减少梯度爆炸和梯度




图 1 LSTM 内部结构图




图 2 BiLSTM 传播示意图

消失, 目前已被广泛应用于带有时间序列规律数据集的预测。LSTM 引入的三个门控单元均采用 Sigmoid 函数激活, 其中遗忘门负责舍去部分无用信息; 输入门负责引入新的信息; 输出门负责细胞状态的输出部分。LSTM 细胞内部结构如图 1。

其细胞内部各门的计算公式如下:

$$\begin{cases} f_t = \sigma(W_f \bullet [h_{t-1}, x_t] + b_f) \\ i_t = \sigma(W_i \bullet [h_{t-1}, x_t] + b_i) \\ o_t = \sigma(W_o \bullet [h_{t-1}, x_t] + b_o) \\ \tilde{C}_t = \tanh(W_c \bullet [h_{t-1}, x_t] + b_c) \\ C_t = f_t \bullet c_{t-1} + i_t \bullet \tilde{C}_t \end{cases} \quad (1)$$

上述公式中 f , i , o 分别表示遗忘门, 输入门和输出门; “ σ ”与“ \tanh ”为激活函数; “ \bullet ”代表两向量的内积; C , c 表示细胞状态和当前单元的状态。

LSTM 通过参数控制可以实现不同数量的输入输出对象的组合, 也可以实现单双向 LSTM 的训练方式。在原始的单向 LSTM 的基础上, BiLSTM 在语义识别等领域被充分证明过其相较于单向 LSTM 训练精度更高, 因为 BiLSTM 可以同时从首尾两个方向运行, 从而同时获得过去和将来的信息, 训练稳定后的精度要高于单向 LSTM。BiLSTM 传播方式如图 2 所示。

图中 A 和 A' 表示正反方向的 LSTM 细胞单元, 每个 BiLSTM 单元都包含正反方向细胞, 使输出端能够附带前后数据的特征。结合本实验研究的目标, 最适合选用多输入单输出的双向 LSTM, 以不同类型车流量, 温度湿度等多种数据输入网络获取车流量预测结果。

CBAM 优化 CNN 特征提取

CNN 介绍

卷积神经网络 (CNN) 具有强大的网格特征提取能力。CNN 传播过程如图 3 所示。

步骤主要包括:

卷积层: 其作用是提取输入数据的特征, 由卷积核对每个通道按顺序滑动窗口, 每个窗口数据同卷积核进行内积操作, 最终可获得包含位置信息的特征矩阵。

池化层: 主要用于挑选卷积层中的特征, 其中常见最大池化和平均池化, 通过选取特征矩阵每部分的最大值, 平均值等对特征进行降维, 减少计算量并避免噪声干扰。

全连接层: 通常连接于池化层后, 其作用是将池化后的特征图连接为长特征向量, 经过隐层输出最终结果。

CBAM 对 CNN 的优化

注意力机制本身属于一种资源分配策略, CBAM (Convolutional Block Attention Module) 是用于 CNN 中的一种包含通道和空间的混合域注意力机制, 通过权重分配减少干扰, 提高模型准确率。CNN 的卷积运算部分是将通道和空间信息混合在一起提取特征, 故引用 CBAM 在这两个维度分别计算特征和权重图进行自适应训练。CBAM 拥有轻量化程度高, 可移植性强等优点, 适配于不同种类的 CNN 可获得更高的性能提升。下图 4 为 CBAM 结构图。

由图 4 可以看出, 在 CBAM 中通道注意力在前, 空间注意力在后。特征图需要先进入通道注意力模块, 基于其宽




图 3 CNN 传播示意图

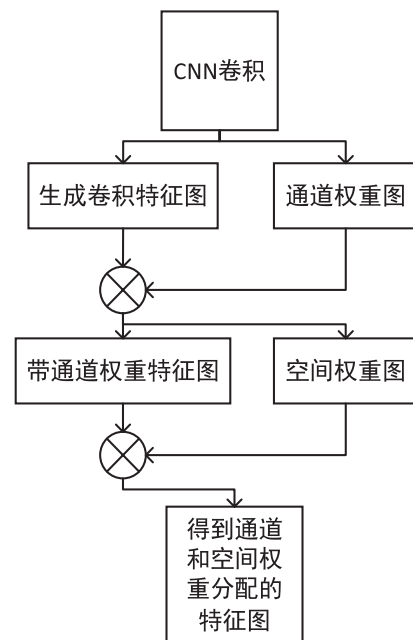


图 4 CBAM 结构示意图

和高的特征进行最大池化和平均池化,然后经过全连接层得出通道注意力权重,然后通过两个特征图的乘法运算为原始特征图加权;通道注意力机制实现公式如下:

$$M_c(F) = \sigma(MLP(AvgPool(F)) + MLP(MaxPool(F))) \quad (2)$$

$$M_c(F) = \sigma(W_1(W_0(F_{avg}^c))) + W_1(W_0(F_{max}^c)) \quad (3)$$

空间注意力机制在通道加权的基础上,同样进行最大池化和平均池化,先把特征维度由宽×高降为1,然后经过 $n \times n$ 的卷积核降低特征图维度,接着再经过一次卷积提升回原有维度,最后将激活后的特征图与通道加权的特征图合并,完成通道和空间两个维度的权重调整。空间注意力机制实现公式如下:

$$M_s(F) = \sigma(f^{n \times n}[AvgPool(F), MaxPool(F)]) \quad (4)$$

$$M_s = \sigma(f^{n \times n}[F_{avg}^s, F_{max}^s]) \quad (5)$$

模型的组成顺序为 CNN 卷积层,通道注意力分配权重、空间注意力分配权重、CNN 池化层、BiLSTM 网络配置以及参数调整。模型的网前向传播流程图如图 5 所示。

实验及结果分析

实验环境及数据

本实验在 Windows10 操作系统搭配 Inter-COREi7

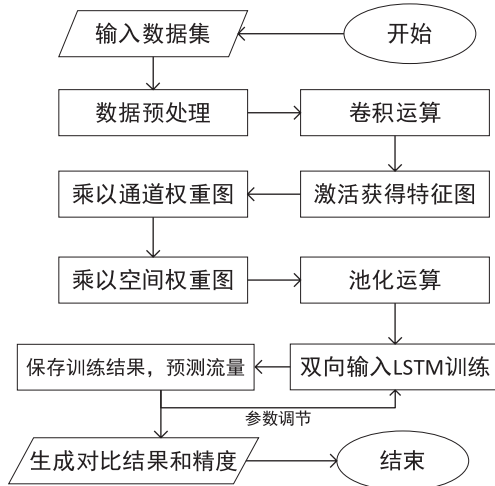


图 5 模型总流程图



图 6 M25 高速监测点位图


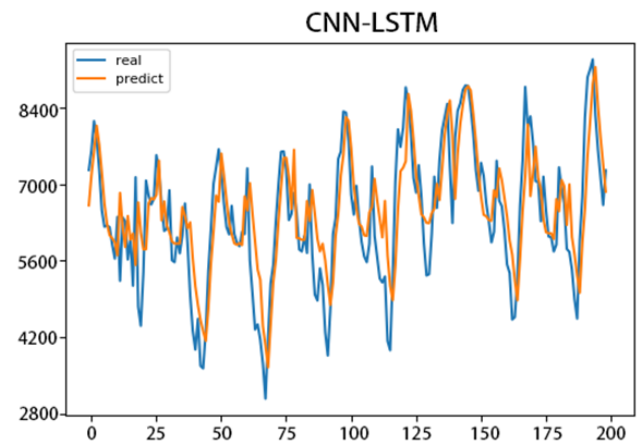

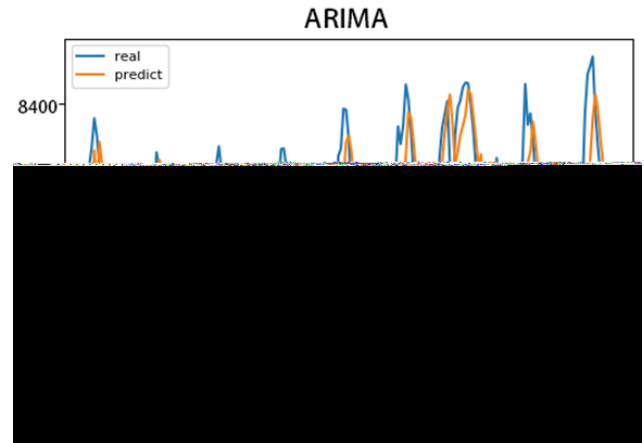


图 7 本文模型同常规模型对比图

处理器环境下进行,采用 Pytorch 深度学习框架,使用 Python 编程实现神经网络,并引用英国 M25 高速公路希思罗机场方向卡口(D3 监测点)2016 年 11 月—2019 年 11 月双向交通流量统计数据,随后补充对应时间机场地区的多列天气数据。最后按 4:1 从中划分出训练数据与测试数据进行图像拟合评估。卡口位置分布如图 6。

图中截取了 D2-D6 共 5 个监测点,其中 D3 监测点位于通往希思罗机场的路口位置附近,交通流更复杂更具有代表性。

本文在原始数据集中提取出 M25 高速 D3 监测点道路和机动车数据,并按时间加入天气数据得到原始数据集,然后对于数据集中存在的缺失和极端错误值采用一次指数平滑预测进行补齐,公式如下:

$$\begin{cases} y_t + 1 = ax_t + (1-a)y_t \\ a \in [0,1] \end{cases} \quad (6)$$

其中 x_t 为 t 时刻的实际值; y_t 为 t 时刻的预测值; a 为平滑系数。至此获得了完整的数据集,但各列之间数量级相差过大。例如车辆数,车道数,天气数据等列之间数量级相差十分巨大,且多个列之间没有互相比较的需要。如果直接输入网络会影响训练精度,因此本文采用 z-score 方法对数据进行标准化处理,公式如下:

$$z = \frac{x - \mu}{\sigma} \quad (7)$$

其中 x 为观测值, μ 为该组观测值的中值, σ 为标准差。

模型参数的确定

本文模型采用 1 层 CNN 卷积和池化,卷积核矩阵大小为 3×3 ,采用 Relu 函数激活; BiLSTM 层的神经元个数为 64,神经元以 1% 的概率随机失活减轻过拟合,学习率为 0.001。BiLSTM 的隐藏层神经单元格数为 128,训练步长为 40,取训练 140 轮的模型进行预测。

实验结果与分析

首先将本文模型与目前常用的交通流预测模型进行对比。其中 ARIMA 采用二阶差分,单 LSTM 以及 CNN-LSTM 组合模型均采用单向多输入网络,由于测试集数据量过大,本文只截取各模型的前 200 条拟合绘图进行对比。效果如图 7 所示。

图 7 中,横坐标代表测试集数据,每条数据间隔一小时,纵坐标代表车辆数。从总体趋势来看大约每 24 小时都会有一组明显的波峰波谷,代表着昼夜车流量的明显变化,有较强随时间演变的规律。将四种模型对比可以看出,ARIMA 模型虽然能预测出大体趋势,但在车流量发生突变,也就是图像的波峰波谷位置与真实值相差较远; LSTM 与 CNN-LSTM 组合模型精度有很大提升,基本可以预测出细微的车流量变化;经 CBAM 优化的 CNN-BiLSTM 预测效果最佳,因为添加了注意力机制使得模型特征提取能力增强,所以对于车流量大小幅度的快速变化能够更为精准的预测。

为了继续探究多种注意力机制对模型的优化效果,本文采用目前常见的 SE, ECA, SAM 三种注意力机制参与对比,其中 SEnet 为单通道维度增加的注意力机制,通过自学习

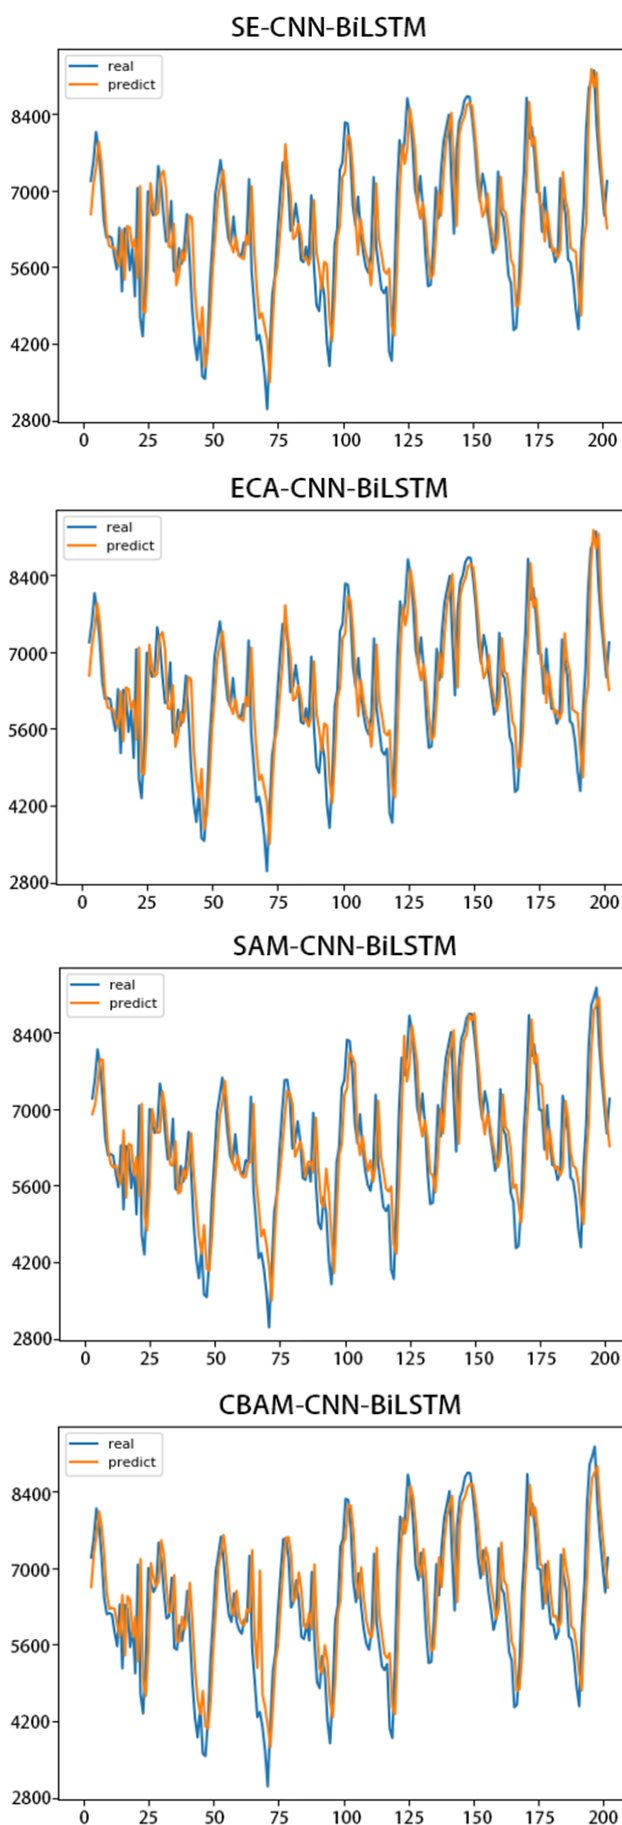


图 8 本文模型同其他注意力机制模型对比图

表 1 常规模型同本文模型对比结果

	ARIMA	LSTM	CNN-LSTM	CBAM-CNN-BiLSTM
RMSE	21.063	6.416	4.965	3.953
MAPE/%	28.49	13.26	11.58	8.87

表 2 其他注意力机制模型同本文模型对比结果

	SE-CNN-BiLSTM	SAM-CNN-BiLSTM	ECA-CNN-BiLSTM	CBAM-CNN-BiLSTM
RMSE	4.816	4.665	4.207	3.953
MAPE/%	9.62	9.48	9.06	8.87

特征权重的方式让 CNN 拥有重点关注通道；ECANet 优化了 SENet，直接在全局平均池化层一维卷积，避免降维影响提高效率；SAM 仅考虑空间维度的优化，先最大池化，平均池化，然后卷积运算。对比效果如图 8 所示。

由图可知，引用注意力机制后整体预测精度有所提升，但不同种类注意力机制相差也不大，难以通过图像观察直接体现细微的差距，需要通过精度评价指标进行量化分析。本文采用均方根误差（RMSE）和平均绝对百分比误差（MAPE）两个指标对以上模型精度定量比较得出优化效果，RMSE 主要用于体现预测值和实际值的偏差情况，通过对最大最小值的敏感反应体现预测准确性；MAPE 是对预测误差绝对值取平均，摆脱符号影响体现预测值和实际值的差别。

二者计算公式如下：

$$RMSE = \left[\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \right]^{\frac{1}{2}} \quad (8)$$

$$MAPE = \frac{1}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{y_i} \quad (9)$$

其中， y_i 是监测点数据集中给出的交通流量数据， \hat{y}_i 是通过模型预测的结果数据， n 为预测数据的数量。

上述常用的交通流预测方法引用公式计算并得到结果如表 1 所示。

由表 1 可以看出本文模型对于以往模型均有精度优势，而且由于本文模型用有非常强的特征捕捉能力，对于强时间序列特征的交通流量数据相比于其他模型可以在更少的训练

次数下接近最优预测结果。

上述不同注意力机制优化的组合模型计算结果如表 2 所示。

由表 2 可以看出，引用注意力机制后预测值相对实际值总体波动更小，更贴近实际值，且因 CBAM 拥有两个层面的权重分配，相比其他注意力机制拥有少量的精度优势；由 MAPE 指标也可以看出 CBAM 注意力机制优化的模型预测值相比实际值误差更低，精度更高。

总结

本文采用 CBAM 优化的 CNN-BiLSTM 模型进行道路短时交通流预测研究，并利用 Python 语言和 PyTorch 框架对模型进行代码实现。通过对比得出，本文模型相对于 ARIMA 模型，单 LSTM 模型和 CNN-LSTM 模型，均方根误差分别降低 17.11，2.463 和 1.012；平均绝对误差比率分别降低 19.62%，4.39% 和 2.71%；相对于 SE，SAM，ECA 三种单一注意力机制优化的 CNN-BiLSTM 模型，均方根误差分别降低 0.863，0.712 和 0.254，平均绝对误差比率分别降低 0.75%，0.61% 和 0.19%。以上实验表明了本文模型对交通流信息的预测可行有效且具有更高的预测准确度。希望本文模型用于交通流量预测问题的研究可以为交管部门的决策以及智能交通系统的构建贡献力量。